

Neural Algorithmic Reasoning con GNNs: Predizione di Interazioni Proteina-Proteina Mancanti tramite Embedding Strutturali

1 Obiettivo della Tesi e Domanda di Ricerca

Domanda di Ricerca: È possibile predire le interazioni mancanti in una rete PPI in modo più accurato rispetto agli algoritmi topologici classici (es. Random Walk with Restart), integrando informazioni strutturali profonde (tramite ESM-2) in una Graph Neural Network?

2 Contesto e Definizione del Problema

2.1 Le Reti PPI (Protein-Protein Interaction)

Le proteine non operano isolatamente; formano complesse reti di interazione.

- **Struttura a Grafo:** La rete è rappresentata come un grafo dove i **Nodi** sono le proteine e gli **Archì** sono le interazioni fisiche o funzionali.
- **Il Problema (Dati Incompleti):** I database attuali (es. STRING, OGB-PPI) sono incompleti o rumorosi a causa di limiti sperimentali. Molti archi mancano ("buchi" nella rete).

2.2 Limiti degli Approcci Attuali (RWR)

Gli algoritmi classici come il **Random Walk with Restart (RWR)** si basano esclusivamente sulla *topologia* (chi è collegato a chi).

- **Fallimento:** Se mancano archi cruciali, RWR non riesce a trovare percorsi o calcola percorsi errati, poiché non ha informazioni sulla natura biologica dei nodi.

3 La Soluzione Proposta: GNN + ESM-2

L'idea centrale è arricchire il grafo topologico con informazioni biologiche e strutturali profonde, permettendo al modello di "ragionare" sulla compatibilità tra proteine anche in assenza di collegamenti espliciti.

3.1 Componenti Chiave

1. **Encoder (ESM-2):** Utilizzi il Large Language Model per proteine **ESM-2** (versione leggera: `esm2_t6_8M_UR50D`). Questo trasforma la sequenza di amminoacidi (es. "MALWMRLL...") in un **vettore numerico** (embedding) che cattura forma, funzione ed evoluzione della proteina.
2. **Processore (GNN):** Una Graph Neural Network che prende in input sia la struttura del grafo che i vettori di ESM-2.
3. **Obiettivo:** La GNN viene addestrata a "imitare" algoritmi di ricerca (come BFS o RWR) su grafi sintetici, imparando a predire dove *dovrebbe* esserci un arco basandosi sulla similarità dei vettori ESM.

4 Pipeline Metodologica

Ecco come procederai, passo dopo passo:

4.1 Passo 1: Preparazione dei Dati

- **Sorgente:** Dataset OGB-PPI o grafo scaricato da STRING (es. *Homo sapiens*).
- **Input:**
 - Elenco degli archi (interazioni note).
 - Sequenze FASTA delle proteine (da STRING o UniProt).

4.2 Passo 2: Feature Engineering (Embedding)

- Ogni sequenza proteica viene passata attraverso `esm2_t6_8M_UR50D`.
- **Risultato:** Ogni nodo del grafo non è più solo un'etichetta ("BRCA1"), ma possiede un vettore denso (es. 1280 dimensioni) che ne descrive le proprietà biochimiche.

4.3 Passo 3: Training (Apprendimento su Grafi Sintetici)

- **Simulazione:** Crei grafi "bucati" rimuovendo casualmente una percentuale di archi (es. 10%) dal grafo originale.
- **Task:** Addestri la GNN a ricostruire questi archi mancanti.
- **Logica:** La GNN impara che se due nodi hanno vettori ESM compatibili, è probabile che esista un'interazione, anche se l'arco è stato rimosso.

4.4 Passo 4: Testing e Validazione

Per valutare il modello, si confrontano le prestazioni della tua GNN contro l'algoritmo classico RWR su un set di archi nascosti (mai visti durante il training).

Scenario di Test:

1. Si seleziona una proteina target (o un set di proteine: *Multi-source*). Seleziona 100 proteine casuali e valuta la media delle prestazioni.
2. Si nascondono le sue interazioni reali. Nello specifico, vengono rimossi (tagliati) ad esempio il 20% degli archi casuali per simulare dati mancanti, oppure aggiunti un 20% di archi casuali (rumore) per verificare la robustezza del modello.
3. Si chiede a **RWR** e alla **GNN** di recuperarle.

5 Metriche di Valutazione

Per quantificare il miglioramento, utilizzerai metriche standard per il *Link Prediction*:

Metrica	Cosa misura?	Perché è importante?
Precision@K	Tra le prime K predizioni, quante sono corrette?	Indica l'affidabilità delle raccomandazioni top-list.
Recall@K	Quante delle interazioni reali nascoste sono state trovate nelle prime K predizioni?	Indica la capacità di copertura del modello.
AUC-ROC	Capacità di distinguere tra un arco vero e uno inesistente.	Misura la robustezza globale del classificatore.

6 Risultati Attesi e Impatto

6.1 Perché la GNN vincerà

- **RWR**: Fallisce sui "ponti mancanti". Se manca l'arco A-B, RWR non può esplorare oltre.
- **GNN**: "Salta" i buchi. Anche senza l'arco A-B, la GNN vede che A e B sono strutturalmente simili/compatibili e predice il collegamento.

6.2 Applicazioni Pratiche

1. **Sviluppo Farmaci**: Identificare nuovi partner di interazione per proteine bersaglio di malattie.
2. **Biologia dei Sistemi**: Completare le mappe di interazione per organismi poco studiati senza costosi esperimenti in laboratorio.